تحلیل عملکرد الگوریتم XGBoost در تشخیص سرطان پستان

مجموعه داده Breast Cancer Wisconsin (Diagnostic) | تهیه‌کننده: فرهان شایان

۱. معرفی کار

در این پروژه می‌خواستیم با استفاده از اندازه‌گیری‌های سلولی که از تصاویر نمونه‌برداری به دست آمده، تومورها را به دو دسته خوش‌خیم و بدخیم تقسیم کنیم. داده‌ها شامل ۵۶۹ نمونه و ۳۰ ویژگی عددی است، مثل شعاع، محیط، مساحت، تقعر و صافی سطح هسته سلول. از این تعداد، ۳۵۷ نمونه خوش‌خیم و ۲۱۲ نمونه بدخیم هستند.

ستون شناسه و یک ستون خالی انتهای فایل حذف شد و برچسب‌ها به صفر (خوش‌خیم) و یک (بدخیم) تبدیل شدند. داده‌ها به نسبت ۸۰ به ۲۰ و با حفظ نسبت دو کلاس تقسیم شد، یعنی ۴۵۵ نمونه برای آموزش و ۱۱۴ نمونه برای آزمون. استانداردسازی ویژگی‌ها فقط روی داده آموزش یاد گرفته شد و بعد روی داده آزمون اعمال شد تا اطلاعات داده آزمون وارد مرحله آموزش نشود.

مدل نهایی XGBoost با ۱۰۰ درخت، نرخ یادگیری ۰٫۱ و عمق حداکثر ۱ ساخته شد. عمق را بعد از امتحان کردن مقادیر ۱ تا ۱۰ انتخاب کردیم. عمق ۱ روی داده آزمون ۹۷٪ دقت داشت و عمق‌های بیشتر ۹۶٪ بودند. مدل‌های عمیق‌تر روی داده آموزش به ۱۰۰٪ می‌رسیدند، که نشانه حفظ کردن داده‌ها بود و نه یادگیری واقعی.

۲. نتایج نهایی روی داده آزمون (۱۱۴ نمونه)

معیار	مقدار	معنی در این پروژه
Accuracy	۹۷٫۳۷٪	از ۱۱۴ نمونه، ۱۱۱ مورد درست تشخیص داده شد
Precision	۱۰۰٪	هر موردی که بدخیم اعلام شد واقعاً بدخیم بود
Recall	۹۲٫۸۶٪	از ۴۲ مورد بدخیم، ۳۹ مورد پیدا شد
F1-score	۹۶٫۳۰٪	میانگین هماهنگ پرسیژن و ریکال
Specificity	۱۰۰٪	هر ۷۲ مورد خوش‌خیم درست شناخته شد

ماتریس درهم‌ریختگی (Confusion Matrix) مدل به این شکل است:

	پیش‌بینی: خوش‌خیم	پیش‌بینی: بدخیم
واقعی: خوش‌خیم	۷۲	۰
واقعی: بدخیم	۳	۳۹

به زبان ساده، مدل هیچ فرد سالمی را اشتباهاً بدخیم ندانست، ولی سه مورد بدخیم را خوش‌خیم تشخیص داد. مهم‌ترین ویژگی‌هایی که مدل برای تصمیم‌گیری استفاده کرد به ترتیب concave points_mean، radius_worst، perimeter_worst، concave points_worst و area_worst بودند.

۳. نقاط قوت الگوریتم

- **دقت بالا با مدل ساده.** با درخت‌هایی که فقط یک مرحله تصمیم‌گیری دارند به ۹۷٪ دقت رسیدیم. یعنی مرز بین دو کلاس در این داده روشن است و به مدل پیچیده نیازی نبود.
- **پرسیژن کامل.** هیچ هشدار اشتباهی داده نشد. در عمل یعنی کسی بی‌دلیل برای بیماری که ندارد وارد مسیر درمان یا آزمایش‌های بعدی نمی‌شود.
- **کنترل بیش‌برازش.** اختلاف دقت آموزش (۹۹٪) و آزمون (۹۷٪) در عمق ۱ کم است. در عمق‌های بالاتر دقت آموزش ۱۰۰٪ بود ولی دقت آزمون پایین‌تر آمد، پس انتخاب مدل ساده تصمیم درستی بود.
- **یادگیری روابط غیرخطی.** درخت‌ها پشت‌سرهم ساخته می‌شوند و هر کدام خطای قبلی را اصلاح می‌کنند. برای ویژگی‌هایی که با هم همبستگی دارند، مثل شعاع، محیط و مساحت، عملکرد پایداری دارد.
- **قابل توضیح بودن.** می‌توان گفت کدام ویژگی‌ها بیشترین نقش را داشتند. در کاربرد پزشکی این مهم است چون پزشک می‌خواهد بداند مدل بر چه اساسی نظر داده.
- **آماده‌سازی تمیز داده.** تقسیم داده با حفظ نسبت کلاس‌ها، مقدار ثابت برای تکرارپذیری و آموزش استانداردساز فقط روی داده آموزش باعث شد نتیجه قابل اعتمادتر باشد.
- **سرعت.** آموزش روی این حجم داده چند ثانیه بیشتر طول نمی‌کشد و فایل مدل ذخیره‌شده سبک است.

۴. نقاط ضعف و محدودیت‌ها

- **ریکال کامل نیست.** سه مورد بدخیم از دست رفت. در تشخیص سرطان، نشناختن یک بیمار واقعی خیلی خطرناک‌تر از یک هشدار اشتباه است. بهبود ریکال باید هدف بعدی باشد، مثلاً با پایین آوردن آستانه تصمیم از ۰٫۵ یا با وزن بیشتر دادن به کلاس بدخیم.
- **کوچک بودن داده آزمون.** فقط ۴۲ نمونه بدخیم داریم. یک مورد اشتباه بیشتر یا کمتر، ریکال را حدود ۲٫۴ درصد جابه‌جا می‌کند، پس نباید اعداد را خیلی دقیق و قطعی تفسیر کرد.
- **انتخاب عمق با داده آزمون.** مقدار عمق را با نگاه کردن به دقت آزمون انتخاب کردیم. این کار نتیجه را کمی خوش‌بینانه می‌کند. روش درست‌تر استفاده از یک مجموعه اعتبارسنجی جدا یا اعتبارسنجی متقاطع (Cross-Validation) است.
- **تنظیم محدود پارامترها.** فقط عمق درخت تغییر داده شد. تعداد درخت‌ها، نرخ یادگیری و پارامترهای تنظیم‌کننده بررسی نشده‌اند و ممکن است نتیجه بهتری بدهند.
- **همبستگی بین ویژگی‌ها.** بسیاری از ویژگی‌ها اطلاعات تکراری دارند (شعاع، محیط و مساحت تقریباً یک چیز را می‌گویند). این موضوع تفسیر اهمیت ویژگی‌ها را سخت‌تر می‌کند.
- **فقط یک منبع داده.** مدل فقط روی همین مجموعه داده ارزیابی شد. برای استفاده واقعی باید روی داده بیمارستان‌های دیگر و دستگاه‌های متفاوت هم آزمایش شود.

۵. نتیجه‌گیری

مدل XGBoost با عمق ۱ در این پروژه عملکرد خوبی داشت: دقت ۹۷٪، پرسیژن ۱۰۰٪، ریکال ۹۳٪ و F1 برابر ۹۶٪. با این حال، به خاطر سه مورد بدخیم از دست‌رفته و کوچک بودن داده آزمون، فعلاً فقط به‌عنوان ابزار کمک‌تشخیصی مناسب است و نباید جای نظر پزشک را بگیرد. قدم‌های بعدی پیشنهادی: اعتبارسنجی متقاطع، تنظیم آستانه تصمیم برای بالا بردن ریکال و آزمایش روی داده خارجی.